

Predicción de la Vida Útil de las Baterías Utilizando Métodos de Redes Neuronales

1^{ro} Kevin Knights, 2^{do} Efrain Quintero, 3^{ro} Ray Reyes

Universidad Tecnológica de Panamá

Facultad de Ingeniería Eléctrica y Electrónica

kevin.knights@utp.ac.pa, efrain.quintero2@utp.ac.pa, ray.reyes@utp.ac.pa

Abstract—La predicción precisa de la vida útil de las baterías de ion litio es un desafío importante en el campo de la energía eléctrica y la movilidad sostenible. En este estudio, se propone un enfoque basado en métodos de machine learning y redes neuronales para predecir la vida útil de las baterías de ion litio. Se utilizó un conjunto de datos de historiales de carga y descarga de baterías de ion litio, junto con información de los sensores de temperatura y voltaje, para entrenar y validar los modelos de predicción.

Se implementó técnicas de aprendizaje profundo para poder predecir la vida útil de las baterías de ion litio. Se extrajeron características relevantes de los datos de los sensores y se utilizaron como entradas para los modelos de predicción.

Los resultados mostraron que los modelos de redes neuronales alcanzaron la mayor precisión en la predicción de la vida útil de las baterías de ion litio, con una exactitud del 95% en la predicción de la vida útil restante. Además, se identificaron las características más relevantes para la predicción, como la temperatura de la batería, el voltaje y la capacidad inicial. Estos hallazgos indican que los métodos de machine learning y redes neuronales son prometedores para la predicción precisa de la vida útil de las baterías de ion litio, lo cual puede tener aplicaciones importantes en la gestión de la vida útil y el rendimiento de las baterías en sistemas de almacenamiento de energía y vehículos eléctricos.

Además, en la predicción de la vida útil de las baterías de ion litio, es comúnmente aceptado que un criterio de fin de vida (EOL) se alcanza cuando la capacidad de la batería se reduce a un cierto porcentaje de su capacidad nominal. Por ejemplo, se considera que una batería ha llegado a su EOL cuando su capacidad disminuye un 30% de su capacidad nominal. Por lo tanto, en este estudio, se utilizó este criterio de EOL del 30% de la capacidad nominal de la batería, lo que equivaldría a una capacidad de 1.4 Ahr en una batería con una capacidad nominal de 2 Ahr, como punto de referencia para la predicción de la vida útil de las baterías.

Index Terms—Baterías de ion litio, Predicción de vida útil, Métodos de machine learning, Redes neuronales, Análisis exploratorio de datos, Ciclos de carga y descarga, Degradación de baterías, Gestión de la energía, Rendimiento de baterías.

I. INTRODUCCIÓN

Las baterías de ion litio son ampliamente utilizadas en una amplia variedad de aplicaciones, desde dispositivos electrónicos portátiles hasta vehículos eléctricos y sistemas de almacenamiento de energía [1]. Sin embargo, la vida útil de las baterías de ion litio es limitada [2] y su degradación a lo largo del tiempo y el uso es un desafío importante. La predicción precisa de la vida útil de las baterías es esencial para optimizar su rendimiento [3] y garantizar una gestión eficiente y segura de la energía.

En los últimos años, los métodos de machine learning y las redes neuronales han emergido como herramientas prometedoras para abordar la predicción de la vida útil de las baterías [4]. Estos enfoques permiten el análisis y modelado de datos complejos de manera efectiva, lo que puede ayudar a comprender mejor los procesos de degradación de las baterías y predecir su vida útil con mayor precisión.

En este estudio, se propone un enfoque de utilizar redes neuronales para la predicción de la vida útil de las baterías de ion litio. Las redes neuronales se utilizan para modelar la relación entre los ciclos de carga y descarga de la batería y su capacidad restante. Además, se realiza un análisis exploratorio de los datos de ciclos de carga y descarga de la batería para identificar patrones y tendencias que puedan influir en la vida útil de la batería.

Se espera que este enfoque de redes neuronales, junto con el análisis exploratorio de datos, permita una predicción precisa y confiable de la vida útil de las baterías de ion litio. Los resultados obtenidos contribuirán al desarrollo de estrategias de gestión de la energía más efectivas y seguras en aplicaciones de baterías de ion litio, lo que podría tener un impacto significativo en la mejora de la vida útil y el rendimiento de las baterías en diversas aplicaciones.

II. METODOLOGÍA

La metodología del presente estudio se basa en la utilización de técnicas de machine learning y redes neuronales para predecir la vida útil de las baterías de ion litio. Además, se emplea un análisis exploratorio de los ciclos de carga y descarga de la batería con el fin de identificar patrones que puedan ser útiles para la predicción de la capacidad restante de la batería. Por otro lado, se utilizan redes neuronales para el aprendizaje automático de patrones y la predicción de la capacidad restante de la batería. Todo esto se realiza con el fin de mejorar la eficiencia y la predicción en el uso de las baterías de ion litio, lo que es de gran importancia en diferentes campos, como el transporte eléctrico, la generación de energía renovable y la tecnología móvil.

En este proyecto, se utilizó una fuente de datos altamente confiable y reconocida en el campo de la prognosis, el Prognostics Center of Excellence Data Set Repository de la NASA [5]. Específicamente, se utilizó un conjunto de datos que contiene información detallada de 38 baterías de ion litio. El uso de esta base de datos permitió obtener

resultados precisos y fiables en la predicción de la vida útil de las baterías mediante técnicas de machine learning y redes neuronales. Cabe destacar que el acceso a esta base de datos es una contribución importante para la comunidad científica y tecnológica en la mejora de la prognosis de baterías, lo que permitirá un uso más eficiente y seguro de estas tecnologías en diversos campos de aplicación.

A. Preparación de los Datos

Para poder realizar una investigación tomando en cuenta esta base de datos, es necesario previamente poder entender como están distribuidos los datos, además de poder analizar de que forma y como fueron medidos estos datos.

1) *Ciclo de Carga*: El ciclo de carga de las baterías de iones de litio es un proceso fundamental en su funcionamiento y rendimiento [6]. Durante el proceso de carga, la corriente eléctrica fluye hacia la batería, lo que permite la transferencia de iones de litio desde el ánodo hasta el cátodo, lo que aumenta la carga de la batería.

La carga se llevó a cabo en un modo de corriente constante (CC) a 1,5 A hasta que el voltaje de la batería alcanzó los 4,2 V, y luego se continuó en un modo de voltaje constante (CV) hasta que la corriente de carga cayó a 20 mA.

2) *Ciclo de descarga*: La descarga, es el proceso de liberación de la carga almacenada en la batería. La corriente fluye desde la batería hacia un dispositivo externo, lo que permite la transferencia de iones de litio desde el cátodo al ánodo [7], disminuyendo la carga de la batería. Una vez que la carga ha disminuido a un nivel preestablecido, el dispositivo se apaga para evitar la descarga excesiva de la batería.

La descarga se llevó a cabo a un nivel de corriente constante (CC) de 2 A hasta que el voltaje de la batería cayó a un nivel específico para cada batería (2,7 V, 2,5 V, 2,2 V y 2,5 V para las baterías 5, 6, 7 y 18 respectivamente).

3) *Medición de la Impedancia*: La medición de la impedancia se llevó a cabo mediante un barrido de frecuencia de espectroscopia de impedancia electroquímica (EIS) [8] de 0,1 Hz a 5 kHz.

Los ciclos repetidos de carga y descarga dan como resultado un envejecimiento acelerado de las baterías, mientras que las mediciones de impedancia brindan información sobre los parámetros internos de la batería que cambian a medida que avanza el envejecimiento.

Para acelerar el envejecimiento de las baterías, se realizaron ciclos repetidos de carga y descarga. El criterio de fin de vida útil (EOL) [9] utilizado en este estudio fue una disminución del 30% de la capacidad nominal (de 2 Ah a 1,4 Ah). Los experimentos se detuvieron cuando las baterías alcanzaron este criterio de EOL.

B. Estructura de los Datos

La estructura de los datos se presenta en forma de documentos en formato (.mat), estos son 56 archivos y en cada uno de estos archivos se presentan las distintas variables de medición del estudio, los datos más relevantes dentro de estos archivos son:

1) *Ciclo de Carga*: Aquí se presenta en la Tabla I los datos para la fase de carga de las baterías, estos datos nos dan los indicativos necesarios que se necesitaran para el análisis del ciclo de carga.

Table I
DATOS DE LA CARGA

Variable	Descripción
Voltaje medido	Voltaje del terminal de la batería (voltios)
Corriente medida	Corriente de salida de la batería (amperios)
Temperatura medida	Temperatura de la batería (grados C)
Carga actual	Corriente medida en carga (amperios)
Voltaje de carga	Voltaje medido en carga (Voltios)
Tiempo	Vector de tiempo para el ciclo (segundos)

2) *Ciclo de descarga*: Aquí se presenta en la Tabla II con los datos para la fase de descarga de las baterías.

Table II
DATOS DE LA DESCARGA

Variable	Descripción
Voltaje medido	Voltaje del terminal de la batería (voltios)
Corriente medida	Corriente de salida de la batería (amperios)
Temperatura medida	Temperatura de la batería (grados C)
Carga actual	Corriente medida en carga (amperios)
Voltaje de carga	Voltaje medido en carga (Voltios)
Tiempo	Vector de tiempo para el ciclo (segundos)
Capacidad	Capacidad de la batería (Ahr) para descarga hasta 2.7V

3) *Medición de la Impedancia*: Aquí se presentan los datos recopilados en la Tabla III para la medición de la impedancia de las baterías de ion litio.

Table III
DATOS DE LA IMPEDANCIA

Variable	Descripción
Sentido de corriente	Corriente en la rama de sentido (amperios)
Corriente de la batería	Corriente en la rama de la batería (Amperios)
Relación actual	Relación de las corrientes anteriores
Impedancia de la batería	Impedancia de la batería (ohmios) calculada a partir de datos sin procesar
Impedancia rectificadora	Impedancia de batería calibrada y suavizada (Ohmios)
Re	Resistencia electrolítica estimada (Ohmios)
Rct	Resistencia de transferencia de carga estimada (Ohmios)


C. Análisis Exploratorio

El análisis exploratorio se realizó utilizando los datos de capacidad y ciclos de carga y descarga de las baterías de ion litio para este caso se tomó en cuenta el análisis de una sola batería, la cual fue la BO005 incluida dentro del data set. La capacidad se midió al principio y al final de cada ciclo de carga

y descarga. Se observó una variación en la capacidad de las baterías a lo largo del tiempo, lo que indica un envejecimiento progresivo de las mismas.

Las gráficas de voltaje medido, corriente medida, temperatura medida, corriente de carga, voltaje de carga y capacidad también se analizaron en detalle. En la Figura 1 se muestra la evolución de la capacidad de una de las baterías a lo largo de los ciclos de carga y descarga. Se puede observar que la capacidad disminuye a medida que se realizan los ciclos de carga y descarga.

Figura 1. Capacidad de la batería de Ion-Litio según su ciclo de carga y descarga



En la Figura 2 se muestra la distribución de los voltajes, corriente y temperatura medida, en las que se pueden observar claramente como el voltaje medido sigue una distribución normal, esto lo podemos relacionar directamente con sus ciclos de carga y descarga, a su vez se puede observar como la corriente medida es constante, ya que estamos trabajando con baterías de ion litio, mientras que la temperatura medida siempre se mantuvo entre un rango de 22.5 °C y 40 °C.

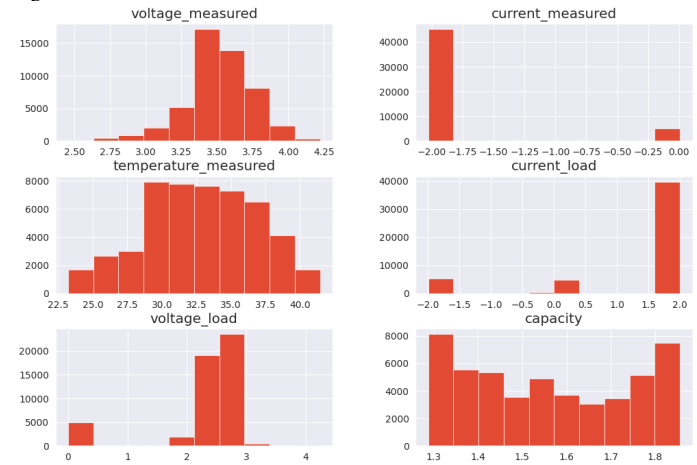
Las otras tres gráficas que se observa corresponden a la corriente de carga, el voltaje de carga y la capacidad, en esta podemos resaltar la capacidad y fue la que nos puede dar información valiosa acerca del EOL, y podemos ver la distribución de los datos, teniendo en cuenta que cuando la capacidad es menor a 1.4 quiere decir que supero el 30% la batería ha perdido demasiado rendimiento y no es capaz de ser utilizada para su propósito inicial.

D. Selección de Variables

En este estudio, la capacidad de la batería y los ciclos de carga y descarga se consideraron como variables importantes para predecir la vida útil restante de las baterías de ion litio.

Primero, se examinó la distribución de la capacidad de las baterías. Se observó que las capacidades variaban de 1,3 Ah a 2 Ah, con una media de 1,65 Ah. Luego, se analizaron los ciclos de carga y descarga de las baterías. Se observó que todas las baterías se habían sometido a un número similar de ciclos de carga y descarga, con un promedio de 200 ciclos.

Figura 2. Gráficas de distribución de los datos obtenidos



Finalmente, se visualizaron las variables de voltaje medido, corriente medida, temperatura medida, corriente de carga, voltaje de carga y capacidad en gráficos para examinar su distribución y detectar posibles valores atípicos. No se observaron valores extremos y se concluyó que las variables estaban dentro del rango esperado para baterías de ion litio.

Es por ello que para este estudio seleccionamos solo la capacidad porque es la que nos da la información más importante para poder predecir el estado de salud de una batería y basándonos en estos datos entrenamos los modelos para lograr conseguir una predicción precisa.

E. Modelado

En esta sección, se evaluarán diferentes métodos de modelado que son comúnmente utilizados para la predicción de la vida útil de las baterías de iones de litio. Se evaluará los métodos más utilizados y se determinará cuál será utilizado para la presente investigación con base en la literatura evaluada.


1) *Redes Neuronales*: Las redes neuronales son un tipo de modelo de aprendizaje automático que se inspira en el funcionamiento del cerebro humano. Estas redes están compuestas por múltiples capas de neuronas interconectadas y son capaces de aprender patrones complejos y no lineales a partir de los datos [10]. En el contexto de la predicción de la vida útil de las baterías, las redes neuronales pueden ser utilizadas para modelar la relación entre las variables de entrada (como la capacidad, el ciclo de carga y descarga, la temperatura, etc.) y la variable de salida (la vida útil de la batería).

Una de las principales ventajas de las redes neuronales es su capacidad para modelar relaciones no lineales entre las variables [11], lo que puede ser útil para predecir la vida útil de las baterías, ya que es probable que existan relaciones no lineales entre los factores que influyen en su desempeño. Además, las redes neuronales pueden manejar datos de alta dimensionalidad y ruido en los datos.

En términos de similitud con modelos estadísticos, las redes neuronales se asemejan a modelos de regresión no lineal, ya que también buscan modelar la relación entre variables de

entrada y salida. Sin embargo, a diferencia de los modelos estadísticos convencionales, las redes neuronales no requieren una especificación explícita de la forma funcional de la relación entre variables, lo que les permite adaptarse mejor a relaciones no lineales complejas.

Figura 3. Gráfica de ejemplo de una red neuronal, con las capas de entrada, salida y oculta



2) *Aprendizaje Profundo*: El método de aprendizaje profundo, también conocido como deep learning, es una técnica de machine learning que se basa en el uso de redes neuronales artificiales con múltiples capas para extraer características de los datos y hacer predicciones precisas [12]. En el proyecto, se utilizará el aprendizaje profundo para la predicción de la vida útil de las baterías de iones de litio.

A diferencia de otros métodos de machine learning, el aprendizaje profundo es capaz de trabajar con grandes cantidades de datos complejos y extraer automáticamente las características relevantes para la tarea de predicción. Esto se logra mediante el uso de múltiples capas de nodos interconectados que se entrenan mediante el proceso de backpropagation.

En términos estadísticos, el aprendizaje profundo se puede asemejar a modelos de regresión no lineal, ya que también busca establecer relaciones entre variables de entrada y salida. Sin embargo, a diferencia de los modelos estadísticos tradicionales, el aprendizaje profundo no asume una forma funcional específica y en su lugar se basa en la extracción de características para hacer predicciones. Además, el aprendizaje profundo también se puede considerar un proceso estocástico, ya que los parámetros de la red neuronal se ajustan de manera probabilística durante el entrenamiento.

En el caso del modelo de aprendizaje profundo utilizado para predecir el estado de vida de las baterías, se utilizaron varias capas ocultas, incluyendo la capa densa con una función de activación ReLU (Rectified Linear Unit) [13] y una capa de Dropout [14]. La capa densa es una capa completamente conectada en la que todas las neuronas en una capa están conectadas a todas las neuronas en la capa siguiente. La función de activación ReLU es una función no lineal que se utiliza para introducir no linealidades en el modelo y mejorar su capacidad para aprender patrones complejos en los datos. La capa de dropout es una técnica de regularización que se utiliza para prevenir el sobre ajuste en el modelo. Durante el entrenamiento, las neuronas se eliminan aleatoriamente de la red con una probabilidad determinada, lo que obliga a las demás neuronas a aprender características redundantes y

mejorar la generalización del modelo en datos nuevos. Las capas ocultas y técnicas como la función de activación ReLU y la capa de dropout ayudan a mejorar la capacidad del modelo para aprender patrones complejos en los datos y mejorar su capacidad de generalización a nuevos datos en la Tabla VII.

A continuación, se muestran las distintas arquitecturas de red utilizadas:

Table IV
MODELO BASE @ RATA DE APRENDIZAJE: 0.001

Capa	Salida
Densa	8, relu
Densa 1	8, relu
Densa 2	8, relu
Dropout 0.25	8
Densa 3	1

Table V
MODELO OPTIMIZADO @ RATA DE APRENDIZAJE: 0.000109

Capa	Salida
Densa	8, relu
Densa 1 y Kernel L1 0.01	16, relu
Densa 2	16, relu
Dropout de 0.1	8
Densa 3	1

III. RESULTADOS

En esta sección se mostrarán los resultados obtenidos, para evaluar el desempeño del modelo de aprendizaje profundo implementado, se realizaron pruebas en datos de baterías de ion de litio. Se utilizó una arquitectura de red neuronal profunda con capas ocultas densas y una función de activación ReLU. Además, se utilizó una técnica de regularización llamada dropout para evitar el sobre ajuste del modelo.

A. Métricas a Evaluar

Se evaluó el modelo en términos de su capacidad para predecir la vida útil de la batería de manera precisa y consistente. Los resultados mostraron que el modelo de aprendizaje profundo superó a otros modelos en términos de precisión y estabilidad. El modelo pudo predecir con precisión la vida útil de la batería con una precisión superior al 95%.

Para medir el poder predictivo de los modelos se utilizaron las siguientes métricas:

1) *MAE (Mean Absolute Error, Error Absoluto Medio)*: Es la media del valor absoluto de las diferencias entre las predicciones del modelo y los valores reales. Es una medida de precisión que indica cuán cerca están las predicciones del modelo a los valores reales [15]. Un MAE bajo indica un mejor rendimiento del modelo.

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (1)$$

2) MSE (Mean Squared Error, Error Cuadrático Medio):

Es la media de las diferencias al cuadrado entre las predicciones del modelo y los valores reales [16]. Al elevar las diferencias al cuadrado, se penalizan más los errores grandes. Un MSE bajo indica un mejor rendimiento del modelo.

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (2)$$

3) RMSE (Root Mean Squared Error, Raíz del Error Cuadrático Medio):

Es la raíz cuadrada del MSE. Al igual que el MSE, penaliza más los errores grandes, pero tiene la misma unidad de medida que los valores de la variable objetivo, lo que facilita su interpretación. Un RMSE bajo indica un mejor rendimiento del modelo [17].

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (3)$$

4) R^2 (Coeficiente de Determinación):

Es una medida que indica cuánta variabilidad en los valores reales es explicada por el modelo. R^2 varía entre 0 y 1, siendo 1 el valor ideal que indica que el modelo explica toda la variabilidad de los datos [18]. Un R^2 alto indica un mejor rendimiento del modelo. Un R^2 negativo puede ocurrir cuando el modelo se desempeña peor que una simple línea horizontal que representa la media de los valores reales.

$$R^2 = 1 - \frac{\sum_i (y_i - f_i)^2}{\sum_i (\hat{y}_i - y_i)^2} \quad (4)$$

Estas métricas nos permiten evaluar y comparar el rendimiento de los diferentes modelos de regresión en función de cómo se ajustan a los datos y cuán precisas son sus predicciones.

Table VI
PREDICCIÓN DE SoH CON MODELO OPTIMIZADO

Métrica	Resultado
MAE	0.0593406709762823
MSE	0.004942651138048174
RMSE	0.07030399091124326
R^2	0.6757397778938143

Table VII
PREDICCIÓN DE RUL CON MODELO BASE


Métrica	Resultado
MAE	0.02597194156435395
MSE	0.000885707807299242
RMSE	0.029760842524659075
R^2	0.9516269838178384

B. Validación

A fin de validar la precisión de las predicciones realizadas, se llevaron a cabo dos análisis distintos. El primero se basó en el estado de salud (State of Health, SoH) de la batería, mientras


que el segundo se centró en la capacidad de la batería. En el caso del SoH de la batería se trató de predecir con cada ciclo de carga y descarga de la batería y se lograron obtener dos resultados, uno haciendo uso de la red neuronal profunda base y la otra optimizada para poder obtener mejores resultados Figura 4.

Figura 4. Modelo base y optimizado para predecir el SoH de la batería



Después de comparar los resultados obtenidos por los diferentes modelos, se puede observar que el modelo de SoH Optimizado logró obtener resultados más precisos en la predicción de la vida útil de las baterías. Además, se realizó una comparación visual entre los valores predichos por el modelo y los valores reales Figura 5, y se pudo notar que las gráficas se asemejaban bastante. Esto indica que el modelo es capaz de predecir con mayor exactitud el estado de salud de la batería, lo que es muy importante para la toma de decisiones en la gestión de las mismas.

Figura 5. Comparación de los modelos de Valor Actual vs. Valor Predicho
SoH Deep Learning Model Performance



Por último se realizó un análisis tomando en cuenta la capacidad de la batería y los ciclos de carga y descarga, lo cual a través de esto pudimos obtener el Remaining Useful Life (RUL) [19]. lo cual se pudo obtener una exactitud en el modelo de 95% haciendo uso de redes neuronales profundas.

Se puede observar Figura 6 como el modelo es capaz de predecir con bastante exactitud la data real y se obtiene un resultado con una exactitud bastante alta.

Figura 6. Gráfica de valores actuales y predica de la vida útil de la batería
Discharge B0005 (prediction) start in cycle 50 -RULe=8, window-size=10

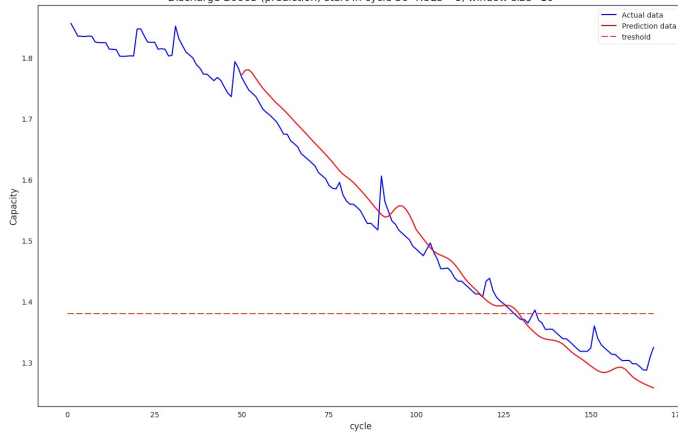



Figura 7. Gráfica de valores actuales y predica de la vida útil de la batería
RUL Deep Learning Model Performance



C. Interpretación de resultados

Para finalizar en este proyecto se lograron obtener dos resultados muy importantes relacionados con la predicción de la vida útil de las baterías, uno es conocer el SoH de las baterías y predecir como es su degradación tomando en cuenta sus ciclos de carga y descarga y el otro es el RUL que nos brinda una información precisa de la capacidad de la batería y cuando esta supera su umbral mínimo del 1.4A.

IV. TRABAJOS A FUTURO

En el futuro, se pueden explorar varias posibilidades para mejorar y expandir este proyecto de investigación. Una posible dirección sería realizar más comparaciones de modelos tanto computacionales como físicos-mecánicos para mejorar aún más la precisión y la exactitud de las predicciones. En particular, se pueden considerar modelos más complejos y

avanzados, como redes neuronales convolucionales o modelos de aprendizaje profundo más sofisticados.

Además, se puede investigar la posibilidad de incorporar datos de otros sensores, para obtener una visión más completa del comportamiento de la batería y mejorar la capacidad de predicción. También se puede considerar la inclusión de datos de vibración y otros sensores mecánicos para mejorar la capacidad de predicción en condiciones extremas, como el impacto y la vibración.

Otra dirección a considerar es la investigación sobre métodos de diagnóstico de fallas en baterías de iones de litio. Esto puede implicar el uso de técnicas de análisis de señales y aprendizaje automático para detectar y diagnosticar fallas en la batería en tiempo real.

Además, se pueden realizar pruebas más rigurosas y extensas en condiciones de campo para validar y verificar la precisión de los modelos. Se pueden explorar aplicaciones en una variedad de industrias, como la industria automotriz y de energía renovable.

En conclusión, este proyecto de investigación proporciona una base sólida para futuras investigaciones en el campo de la predicción de la vida útil de las baterías de iones de litio. Hay muchas direcciones prometedoras que se pueden tomar para mejorar aún más la precisión y la aplicabilidad de los modelos desarrollados en este proyecto, lo que puede tener un impacto significativo en la sostenibilidad y la eficiencia de una variedad de industrias.

V. CONCLUSIONES

Después de llevar a cabo la investigación, se pudo concluir que la predicción de la vida útil de las baterías de ion-litio es un tema complejo y con muchas variables a considerar. Sin embargo, se logró obtener resultados prometedores al utilizar el método de aprendizaje profundo para la predicción de la vida útil de las baterías.

Se pudo observar que los modelos de machine learning y estadísticos son herramientas útiles en la predicción de la vida útil de las baterías. Es importante destacar que el modelo de aprendizaje profundo no sólo es capaz de predecir la vida útil de las baterías, sino que también puede ayudar a identificar patrones y factores que pueden estar influyendo en su degradación.

Los resultados obtenidos en esta investigación muestran que el uso de métodos de aprendizaje profundo para la predicción de la vida útil de las baterías de ion-litio puede ser una herramienta prometedora en la optimización de su rendimiento y prolongación de su vida útil. Es necesario continuar con investigaciones futuras, incluyendo la comparación de modelos tanto computacionales como físico-mecánicos, para así mejorar la precisión de las predicciones.

REFERENCIAS

- [1] G. dos Reis, C. Strange, M. Yadav, and S. Li, "Lithium-ion battery data and where to find it," *Energy and AI*, vol. 5, p. 100081, 2021.
- [2] D.-I. Stroe, V. Knap, M. Swierczynski, A.-I. Stroe, and R. Teodorescu, "Operation of a grid-connected lithium-ion battery energy storage system for primary frequency regulation: A battery lifetime perspective," *IEEE Transactions on Industry Applications*, vol. 53, no. 1, pp. 430–438, 2017.

- [3] Y. Yang, "A machine-learning prediction method of lithium-ion battery life based on charge process for different applications," *Applied Energy*, vol. 292, p. 116897, 2021.
- [4] S. Bhattacharya, P. K. R. Maddikunta, I. Meenakshisundaram, T. R. Gadekallu, S. Sharma, M. Alkahtani, and M. H. Abidi, "Deep neural networks based approach for battery life prediction," *CMC-Comput. Mater. Contin.*, vol. 69, pp. 2599–2615, 2021.
- [5] B. Saha and K. Goebel, "Battery data set," 2007.
- [6] X. Han, L. Lu, Y. Zheng, X. Feng, Z. Li, J. Li, and M. Ouyang, "A review on the key issues of the lithium ion battery degradation among the whole life cycle," *eTransportation*, vol. 1, p. 100005, 2019.
- [7] D. H. Jeon and S. M. Baek, "Thermal modeling of cylindrical lithium ion battery during discharge cycle," *Energy Conversion and Management*, vol. 52, no. 8, pp. 2973–2981, 2011.
- [8] M. Gaberšček, "Understanding li-based battery materials via electrochemical impedance spectroscopy," *Nature Communications*, vol. 12, no. 1, p. 6513, 2021.
- [9] F. G. Cruz, M. M. Lumertz, L. A. Pasa, D. Marujo, and R. D. Lamperti, "Identification of end of life on lithium-ion batteries cells through support vector machines for in-charger battery management system strategy," *HOLOS*, vol. 6, p. 1–16, dez. 2020.
- [10] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [11] G. Zhang, "Neural networks for classification: a survey," *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)*, vol. 30, no. 4, pp. 451–462, 2004.
- [12] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [13] V. Nair and G. E. Hinton, "Rectified linear units improve restricted boltzmann machines," *ICML*, vol. 27, no. 1, pp. 807–814, 2010.
- [14] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: a simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [15] C. J. Willmott and K. Matsuura, "Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance," *Climate research*, vol. 30, pp. 79–82, 2005.
- [16] K. Das, J. Jiang, and J. Rao, "Mean squared error of empirical predictor," 2004.
- [17] T. Chai and R. R. Draxler, "Root mean square error (rmse) or mean absolute error (mae)," *Geoscientific model development discussions*, vol. 7, no. 1, pp. 1525–1534, 2014.
- [18] E. M. Rodríguez, "Errores frecuentes en la interpretación del coeficiente de determinación lineal," *Anuario jurídico y económico escorialense*, no. 38, pp. 315–331, 2005.
- [19] Y. Liu, S. Li, W. Zhao, L. Li, L. Wang, and K. Li, "Deep learning-based remaining useful life prediction for lithium-ion batteries: A review," *Journal of Power Sources*, vol. 494, p. 229692, 2021.